Práctica Final:
Análisis y Predicción de Series Temporales

Competición Kaggle – Universidad Rey Juan Carlos (URJC)

Gonzalo C. Gómez

Mayo 2026

Contents

1 Introducción **3**

2 Descripción de los Datos **3**

3 Serie A – Precios Bursátiles Diarios **3**
3.1 Análisis exploratorio . . . 3
3.2 Estacionariedad . . . 4
3.3 Selección del modelo . . . 4
3.4 Análisis de residuos . . . 5
3.5 Predicciones . . . 6

4 Serie B – Nacimientos Diarios **6**
4.1 Análisis exploratorio . . . 6
4.2 Modelo: SARIMA con términos de Fourier . . . 7
4.3 Análisis de residuos . . . 8
4.4 Predicciones . . . 9

5 Serie C – Temperatura Global Mensual **9**
5.1 Análisis exploratorio . . . 9
5.2 Estacionariedad . . . 10
5.3 Selección del modelo . . . 10
5.4 Análisis de residuos . . . 11
5.5 Predicciones . . . 12

6 Serie D – Serie Mensual **12**
6.1 Análisis exploratorio . . . 12
6.2 Estacionariedad . . . 13
6.3 Selección del modelo . . . 13
6.4 Análisis de residuos . . . 14
6.5 Predicciones . . . 15

7 Investigación Adicional **16**

7.1 Serie A – Heterocedasticidad y log-retornos 16
7.2 Serie B – Exploración con Gradient Boosting 17
7.3 Serie D – Transformación Box-Cox 17

8 Resultados y Conclusiones **19**

1 Introducción

El objetivo de esta práctica es predecir cuatro series temporales de naturaleza muy diferente para la competición Kaggle de la asignatura. Para cada una se ha seguido el mismo proceso: análisis exploratorio, test de estacionariedad, selección del modelo por RMSE en validación y predicción final reajustando sobre todos los datos disponibles.

El enfoque utilizado en todas las series es SARIMA/SARIMAX (Seasonal AutoRegressive Integrated Moving Average with eXogenous regressors). Para la serie B, que presenta doble estacionalidad (semanal y anual), se combina SARIMA con términos de Fourier anuales como regresores externos. En la serie C se añade también un regresor de tendencia lineal.

Las herramientas usadas son Python 3.10 con `pandas`, `statsmodels` y `matplotlib`.

2 Descripción de los Datos

Table 1: Resumen de las series temporales

Serie	Variable	Frecuencia	Obs. train	Período train	Preds.
A	Precio bursátil	Diaria (lab.)	2025	2010–2018	10
B	Nacimientos diarios	Diaria	3287	1994–2002	365
C	Temp. global (°C)	Mensual	1740	1880–2024	12
D	Serie mensual	Mensual	132	1980–1990	10

3 Serie A – Precios Bursátiles Diarios

3.1 Análisis exploratorio

La serie A contiene 2025 observaciones de precios bursátiles en días laborables (julio 2010 – septiembre 2018). La tendencia alcista es clara: el precio pasa de unos 120 a más de 220.

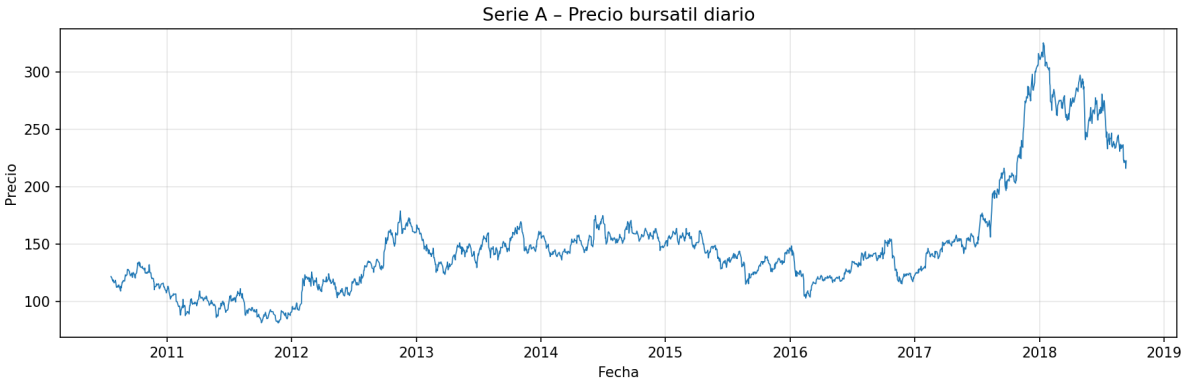

Figure 1: Serie A: precios bursátiles diarios (2010–2018)

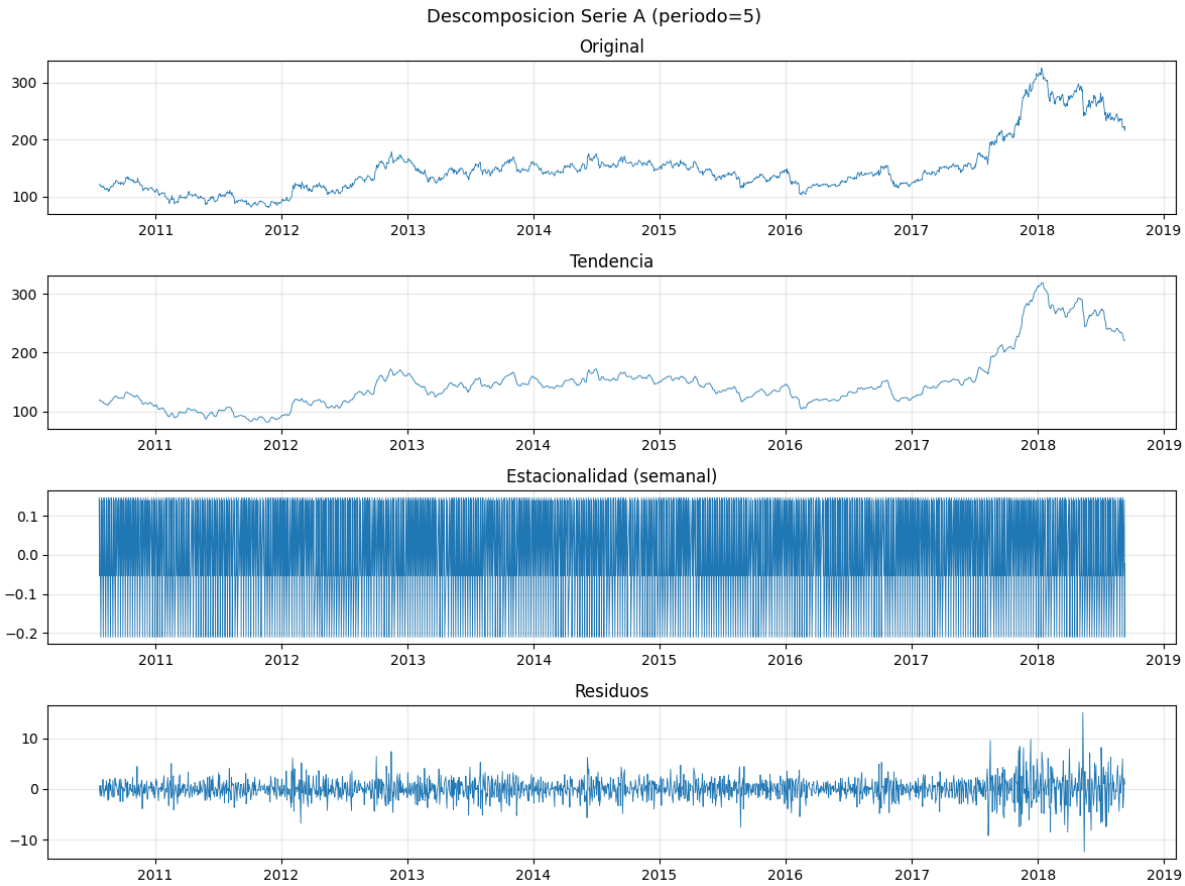

Figure 2: Descomposición aditiva de la Serie A (período = 5 días laborables)

3.2 Estacionariedad

El test ADF en niveles da $p = 0.74$, así que la serie no es estacionaria. Con la primera diferencia cae a $p < 0.0001$, lo que confirma integración de orden 1. El ACF y PACF de la serie diferenciada no muestran autocorrelaciones relevantes, lo que es coherente con un precio que sigue aproximadamente un paseo aleatorio.

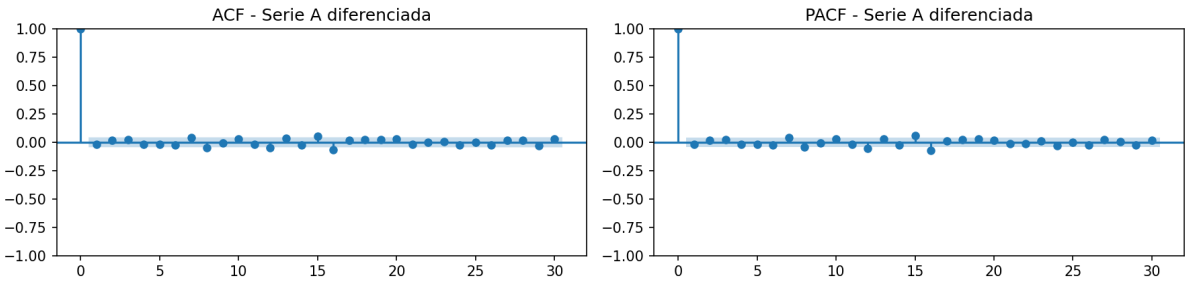

Figure 3: ACF y PACF de la Serie A (primera diferencia)

3.3 Selección del modelo

Se realizó un grid search SARIMA con $m = 5$ días laborables (estacionalidad semanal). El mejor modelo en validación (últimas 20 observaciones) fue **SARIMA**$(2, 0, 1)(1, 1, 1)_5$

con RMSE= 6.16.

Con $d = 0$ y $D = 1$, la diferenciación estacional estabiliza la serie sin perder la información de nivel. El término AR(2) ordinario captura la dinámica de corto plazo (la correlación entre días consecutivos).

Table 2: Selección SARIMA – Serie A (validación: últimas 20 obs.)

Modelo	**RMSE (val.)**	**AIC**
SARIMA$(2,0,1)(1,1,1)_5$	**6.16**	10378.55
SARIMA$(2,0,1)(0,1,1)_5$	6.24	10349.53
SARIMA$(0,0,2)(1,0,0)_5$	6.26	11746.16

3.4 Análisis de residuos

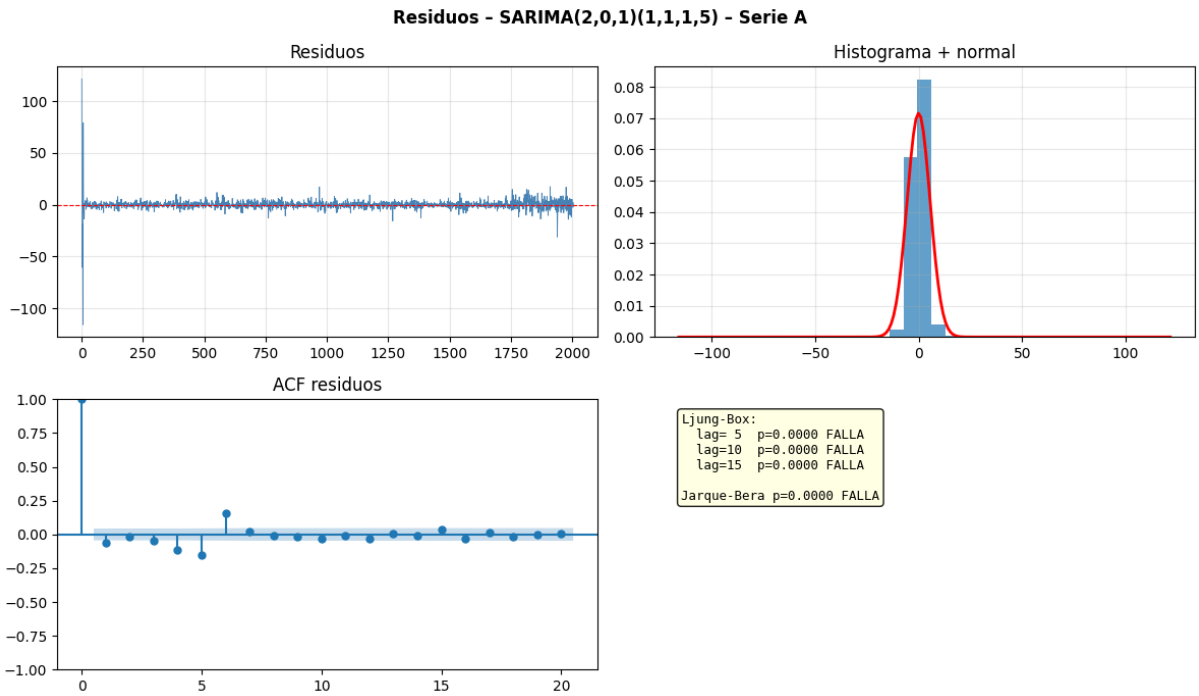

Figure 4: Análisis de residuos – SARIMA$(2,0,1)(1,1,1)_5$ – Serie A

3.5 Predicciones

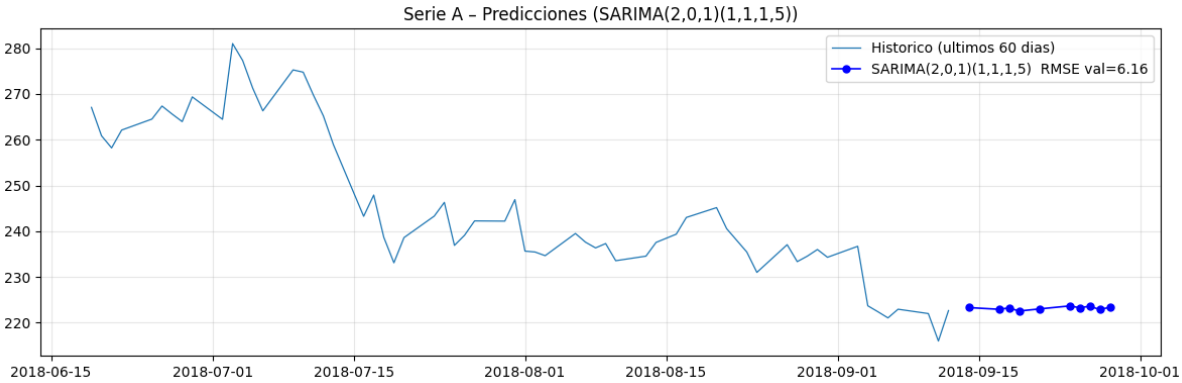

Figure 5: Serie A: predicciones SARIMA$(2,0,1)(1,1,1)_5$ para los 10 días de test

4 Serie B – Nacimientos Diarios

4.1 Análisis exploratorio

La serie B contiene 3287 observaciones diarias de nacimientos (1994–2002). Tiene dos estacionalidades claramente visibles: una semanal muy marcada (pocos nacimientos en fin de semana, las cesáreas programadas se concentran entre semana) y una anual (pico en agosto-septiembre, mínimo en enero, diferencia de unos 1000 nacimientos/día).

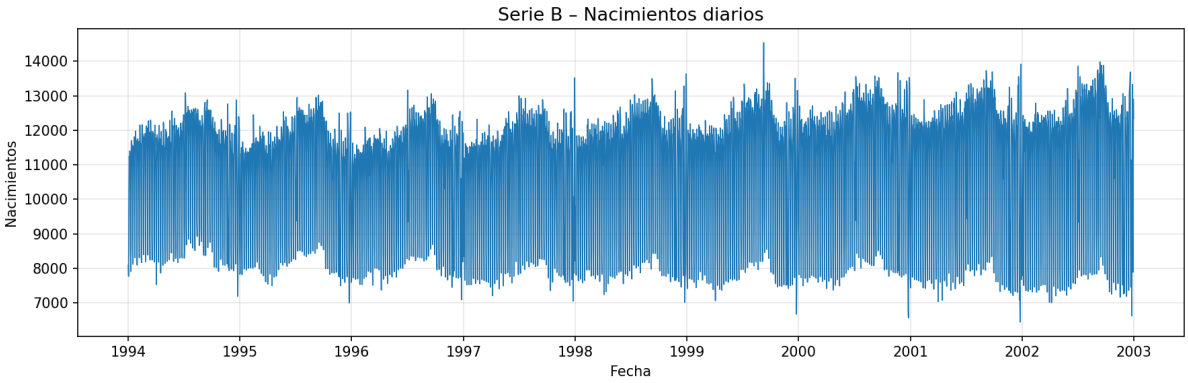

Figure 6: Serie B: nacimientos diarios (1994–2002)

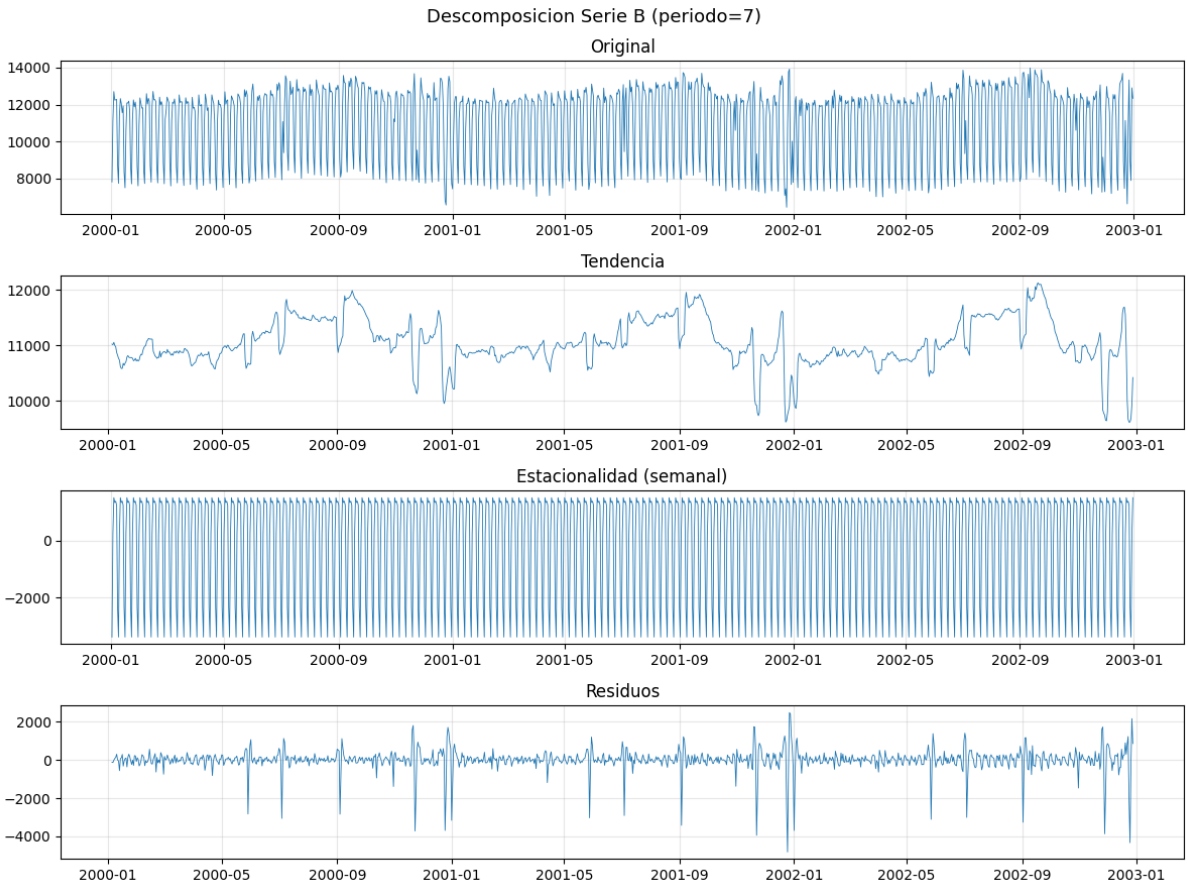

Figure 7: Descomposición de la Serie B (período = 7 días)

4.2 Modelo: SARIMA con términos de Fourier

Motivación del enfoque

La serie tiene dos estacionalidades distintas. SARIMA con $m = 7$ captura directamente la componente semanal mediante diferenciación estacional y los términos AR/MA estacionales. Sin embargo, la componente anual no puede modelarse con un segundo periodo estacional en SARIMA estándar.

Para resolver esto se añaden como regresores externos **términos de Fourier anuales**: pares seno/coseno de la forma

$$\sin\left(\frac{2\pi k\, t}{365.25}\right), \quad \cos\left(\frac{2\pi k\, t}{365.25}\right), \quad k = 1, \ldots, K$$

donde t es el día del año (1–365). Con $K = 5$ se tienen 10 regresores que representan los primeros cinco armónicos de la variación anual. La ventaja de este enfoque es que estos regressores se calculan únicamente a partir del índice de fecha, sin usar los valores de la serie, así que no hay fuga de información al construirlos para 2003. El modelo SARIMAX con $m = 7$ y Fourier $K = 5$ separa entonces las dos fuentes de variación: el componente estocástico semanal (manejado por el SARIMA) y el patrón anual determinista (manejado por el Fourier).

Selección del modelo

Se realizó un grid search con $m = 7$ y $K = 5$, entrenando con 1994–2001 y validando en 2002. El mejor modelo fue **SARIMA**$(2,0,1)(1,1,1)_7$ con Fourier $K = 5$ (RMSE= 710 sobre el año 2002, entrenado con todos los años disponibles).

Table 3: Top modelos – Serie B (validación: año 2002)

Modelo	**K**	**Ventana**	**RMSE (val.)**
SARIMA$(2,0,1)(1,1,1)_7$	**5**	**all**	**710.10**
SARIMA$(2,0,0)(1,1,1)_7$	5	all	712.25
SARIMA$(1,0,2)(1,1,1)_7$	5	all	712.63

4.3 Análisis de residuos

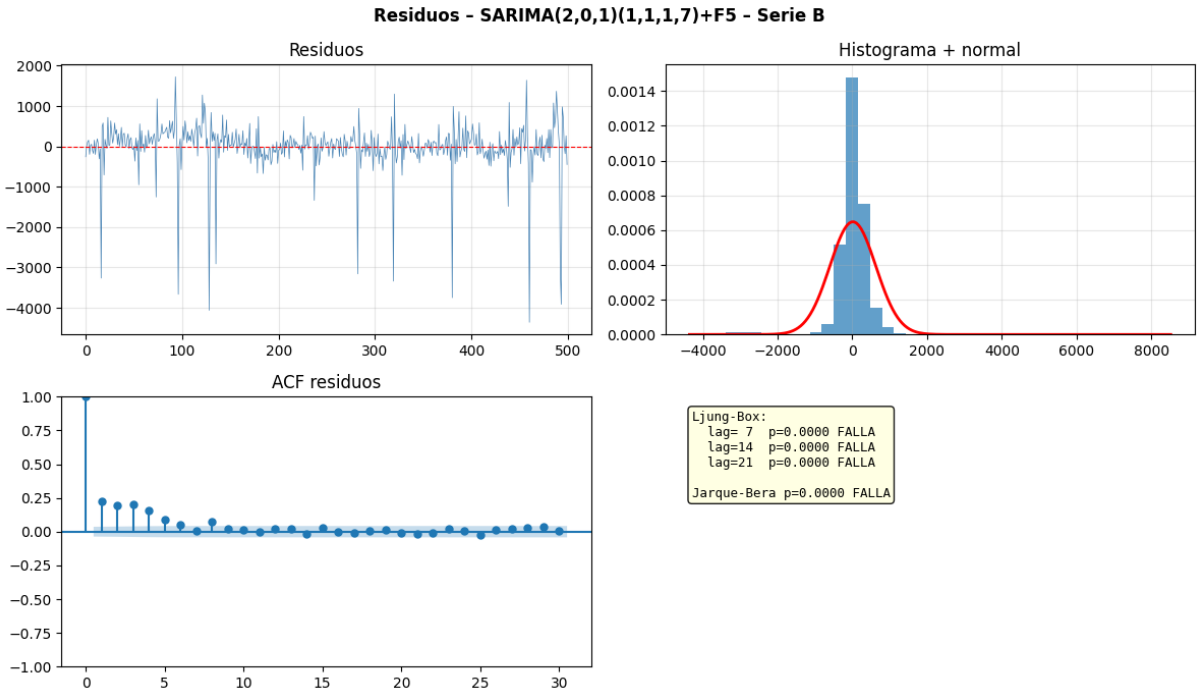

Figure 8: Análisis de residuos – SARIMA$(2,0,1)(1,1,1)_7$ + Fourier $K = 5$ – Serie B

4.4 Predicciones

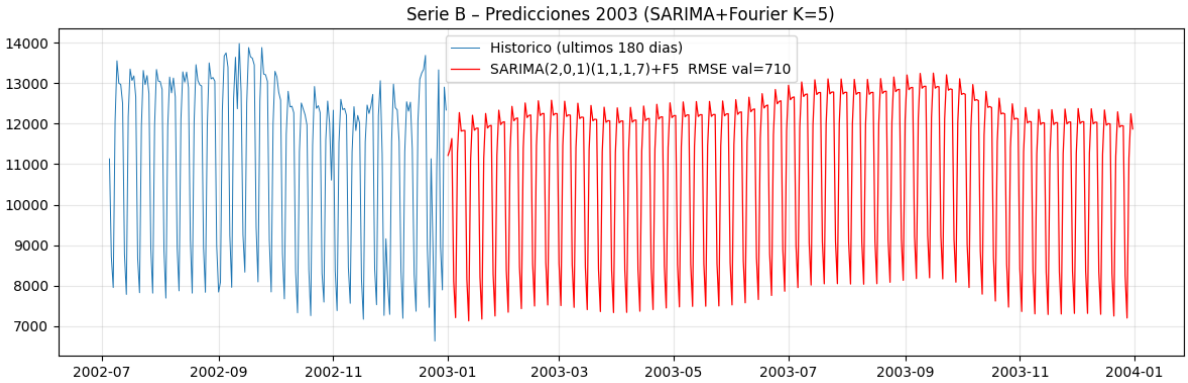

Figure 9: Serie B: predicciones para el año 2003 (SARIMA + Fourier $K = 5$)

5 Serie C – Temperatura Global Mensual

5.1 Análisis exploratorio

La serie C tiene temperaturas medias globales mensuales desde 1880 hasta 2024 (1740 observaciones). Se observa claramente el calentamiento global como tendencia ascendente, especialmente acelerado desde los años 80, y una pequeña estacionalidad anual.

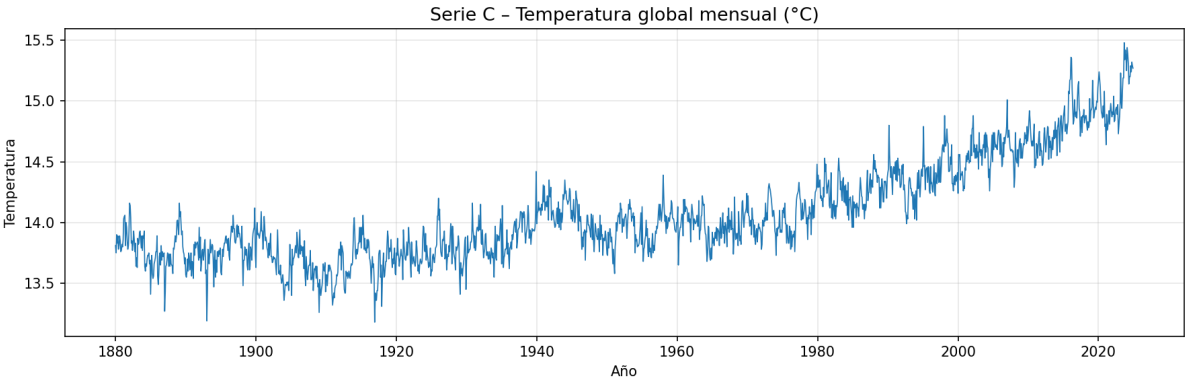

Figure 10: Serie C: temperatura global mensual (°C), 1880–2024

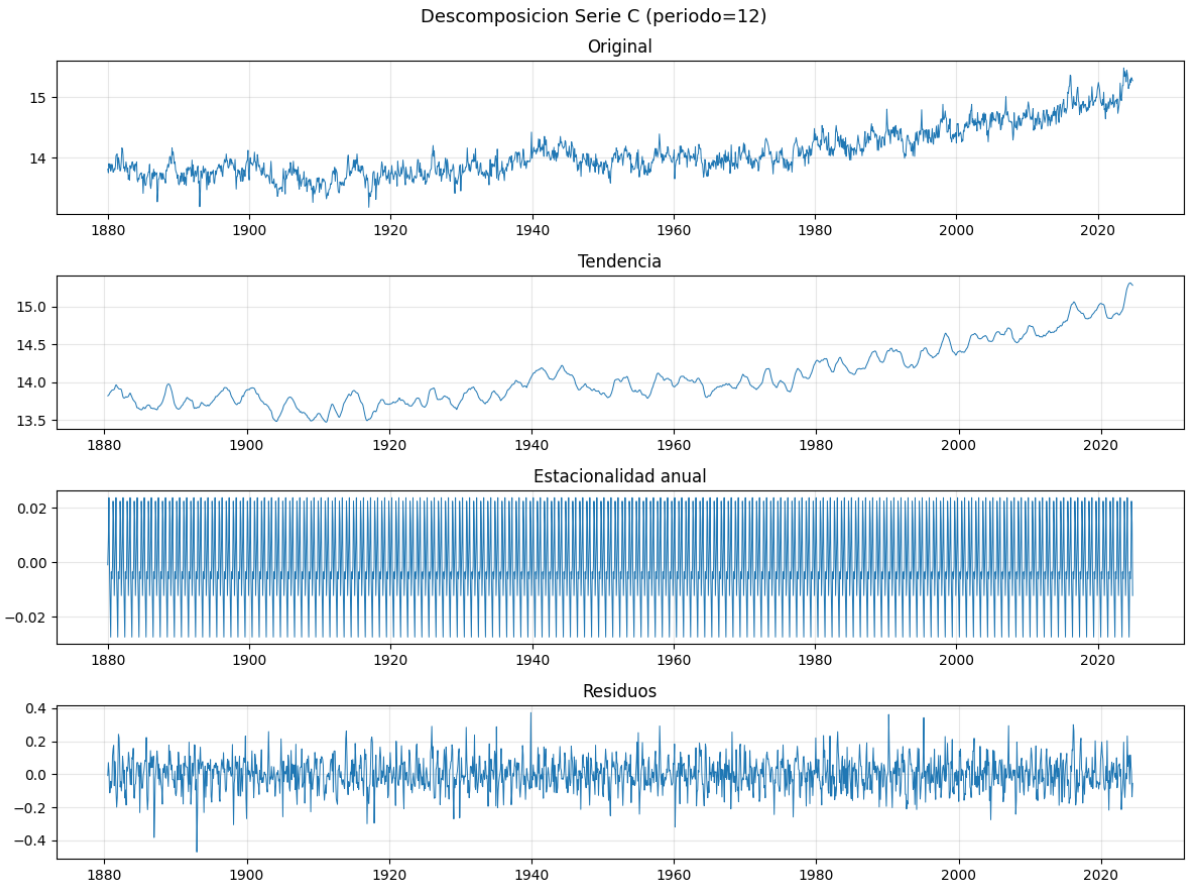

Figure 11: Descomposición de la Serie C (período = 12 meses)

5.2 Estacionariedad

El ADF en niveles da $p = 0.97$ (no estacionaria). Con diferenciación estacional de orden 12 baja a $p < 0.0001$.

5.3 Selección del modelo

Se entrenó sobre los **últimos 40 años** (1985–2024, 480 observaciones) en vez de usar la serie completa desde 1880. La razón es que la tendencia de calentamiento reciente es mucho más pronunciada que la de finales del siglo XIX y principios del XX: los datos antiguos tienen una pendiente muy diferente a la actual y distorsionan las predicciones a corto plazo.

El mejor modelo fue **SARIMA**$(1,0,0)(0,1,1)_{12}$ con un **regresor de tendencia lineal** (RMSE= 0.287 en validación, últimos 24 meses). La tendencia lineal exógena modela el calentamiento global continuo de forma explícita; la diferenciación estacional $D = 1$ elimina el patrón mensual.

Table 4: Top modelos – Serie C (validación: 2023–2024)

Modelo	Ventana	RMSE (val.)
SARIMA$(1,0,0)(0,1,1)_{12}$ **+ tendencia**	**40 años**	**0.2870**
SARIMA$(0,0,1)(0,1,1)_{12}$ + tendencia	40 años	0.2894
SARIMA$(0,0,1)(0,1,1)_{12}$	40 años	0.2895

5.4 Análisis de residuos

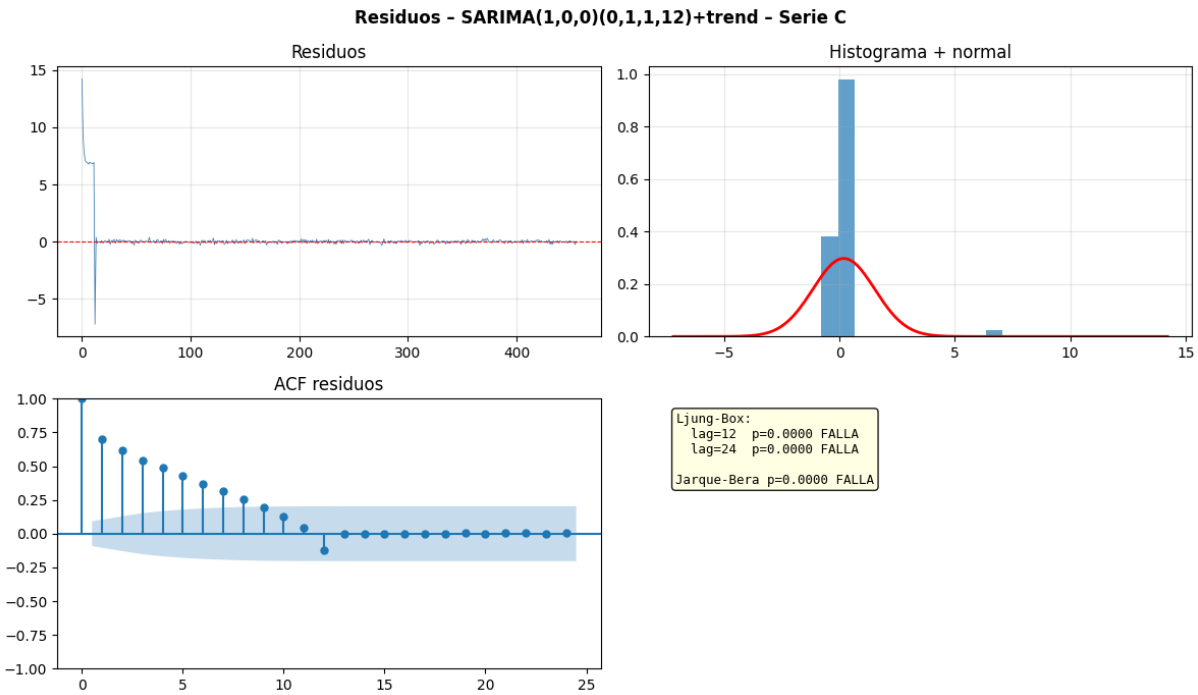

Figure 12: Análisis de residuos – SARIMA$(1,0,0)(0,1,1)_{12}$ + tendencia – Serie C

5.5 Predicciones

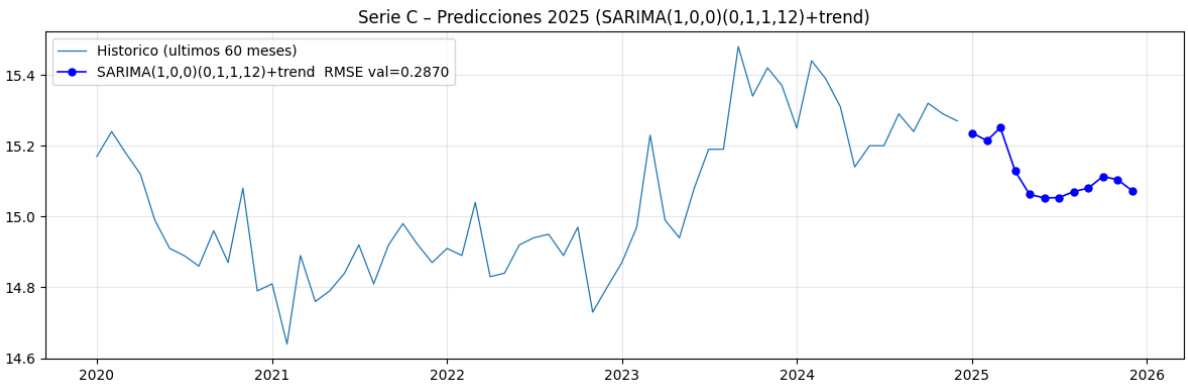

Figure 13: Serie C: predicciones SARIMA$(1,0,0)(0,1,1)_{12}$ para 2025

6 Serie D – Serie Mensual

6.1 Análisis exploratorio

La serie D tiene 132 observaciones mensuales (1980–1990). Los valores crecen de forma sostenida (de ≈ 464 a ≈ 2286) con una estacionalidad anual clara. Probablemente son datos de consumo (gas o electricidad).

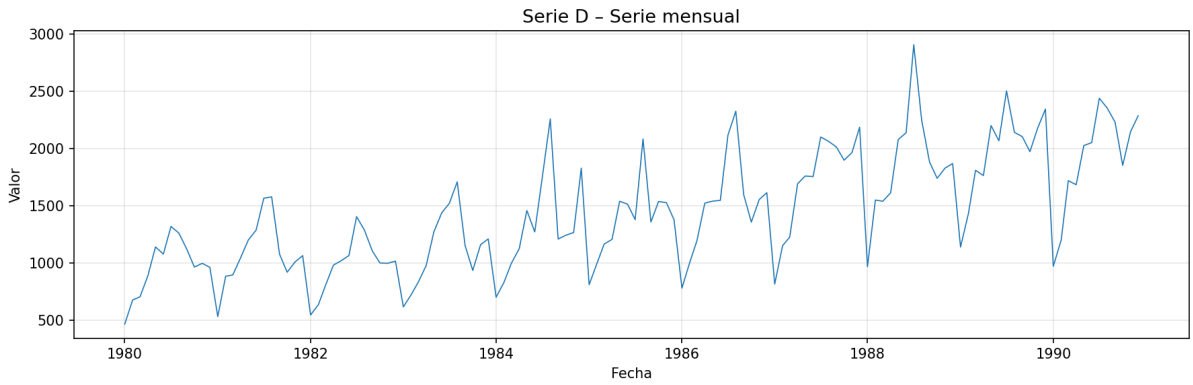

Figure 14: Serie D: serie mensual (1980–1990)

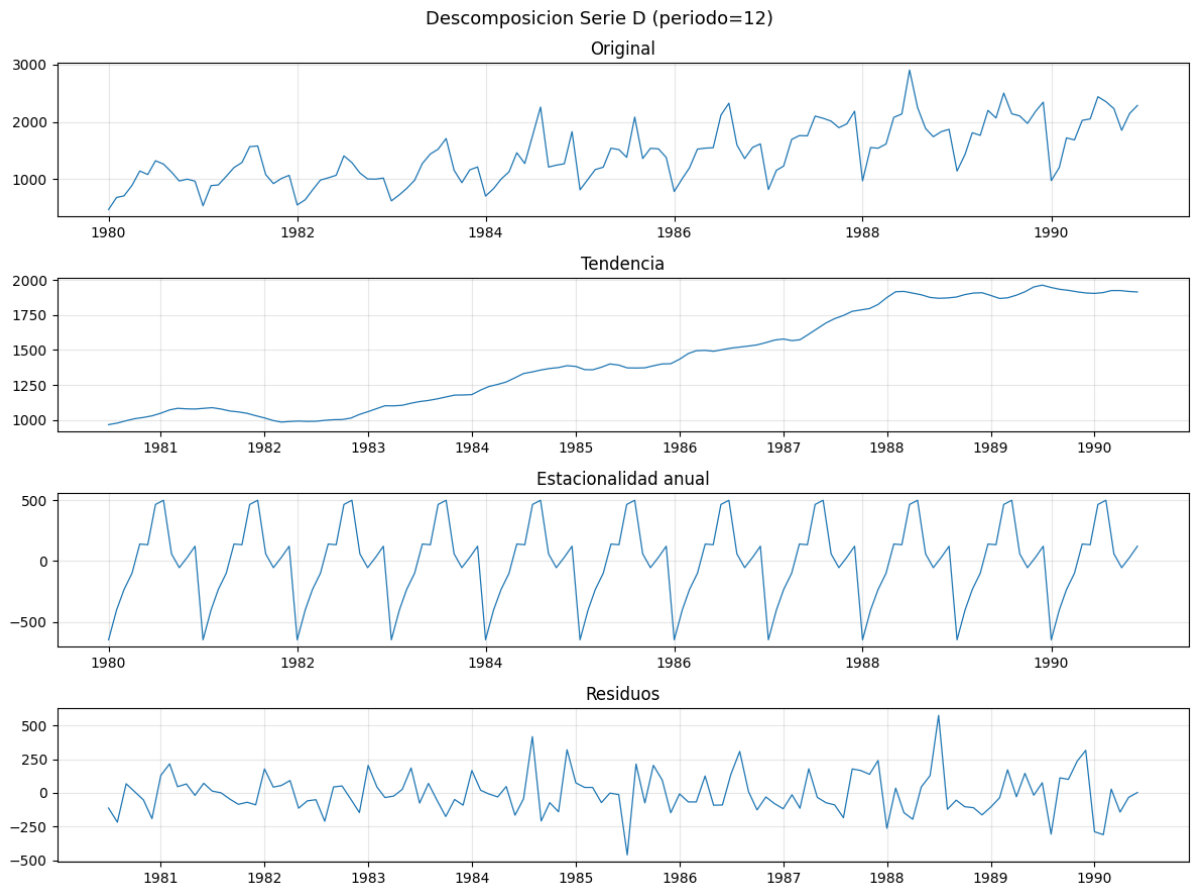

Figure 15: Descomposición de la Serie D (período = 12 meses)

6.2 Estacionariedad

ADF en niveles: $p = 0.92$ (no estacionaria). Con diferenciación estacional: $p = 0.0003$.

6.3 Selección del modelo

El mejor modelo en validación (año 1990) fue **SARIMA**$(0,0,0)(1,0,0)_{12}$ con RMSE= 186.24. Este modelo solo tiene el componente AR estacional de orden 1: cada observación es una fracción del mismo mes del año anterior. Su simplicidad es su ventaja, ya que no sobre-ajusta en una serie de solo 132 observaciones.

Table 5: Top modelos – Serie D (validación: año 1990)

Modelo	RMSE (val.)	AIC
SARIMA$(0,0,0)(1,0,0)_{12}$	**186.24**	1483.61
SARIMA$(0,0,1)(1,0,0)_{12}$	193.89	1473.83
SARIMA$(0,0,0)(0,1,1)_{12}$	193.98	1283.23

6.4 Análisis de residuos

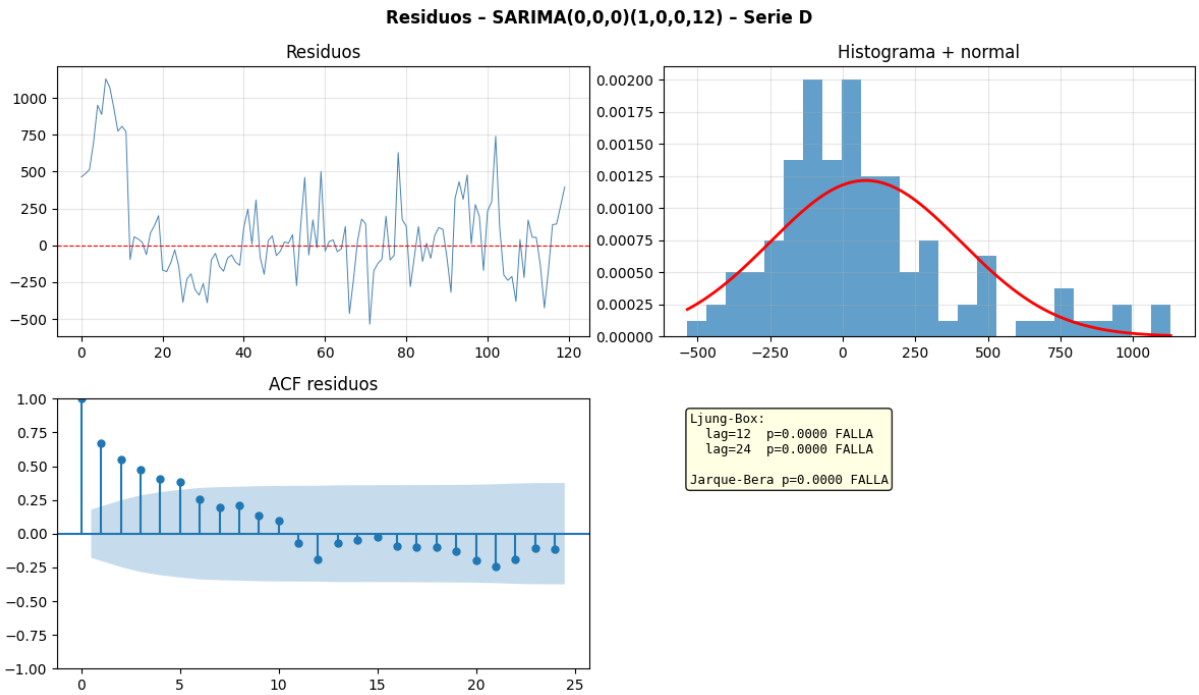

Figure 16: Análisis de residuos – SARIMA$(0,0,0)(1,0,0)_{12}$ – Serie D

6.5 Predicciones

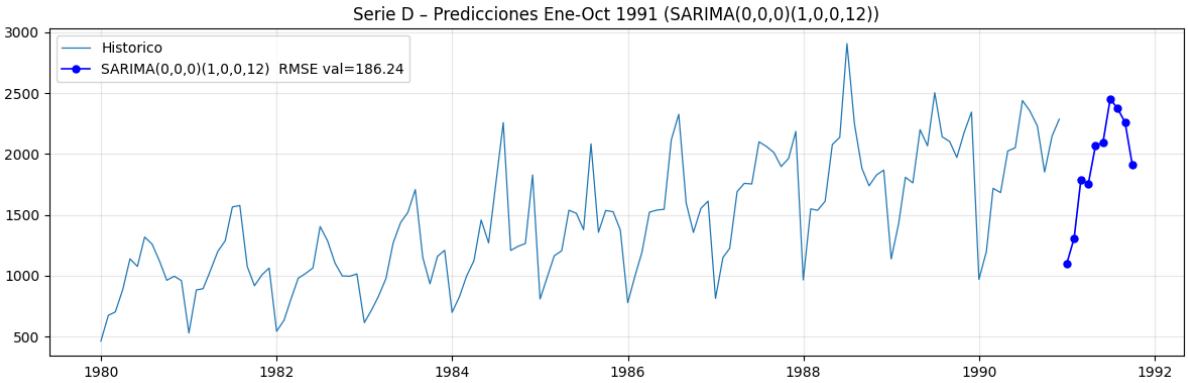

Figure 17: Serie D: predicciones para enero–octubre de 1991

7 Investigación Adicional

Además del análisis principal, exploré algunas cuestiones adicionales que aparecieron durante el trabajo.

7.1 Serie A – Heterocedasticidad y log-retornos

La serie de precios es heterocedástica: cuando el precio es alto, también lo son las oscilaciones diarias. Aplicando el test de Levene [5] dividiendo la serie en 4 bloques, el p-valor es prácticamente cero.

En finanzas lo habitual es trabajar con **log-retornos** ($r_t = \log P_t - \log P_{t-1}$), que son estacionarios y mucho más homocedásticos. Ajusté un ARIMA sobre los retornos y luego revertí la transformación para obtener precios. El modelo resultante fue ARIMA$(0, 0, 0)$ (ruido blanco), coherente con la hipótesis de eficiencia del mercado.

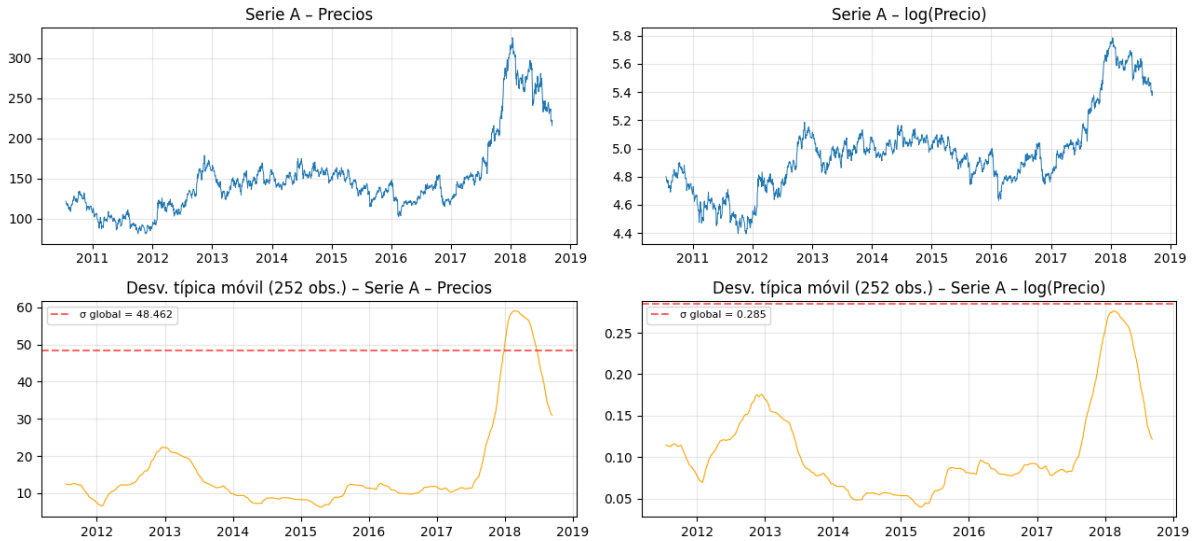

Figure 18: Serie A: desviación típica móvil de precios (izquierda) y log-precios (derecha). La transformación reduce bastante la heterocedasticidad.

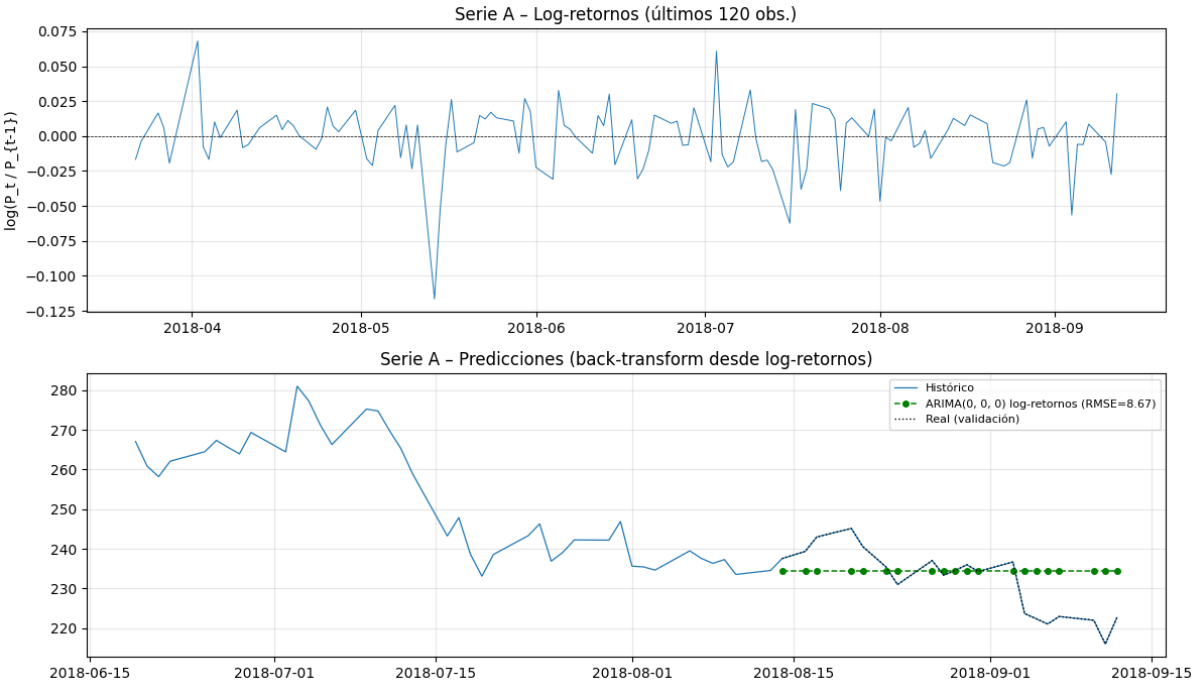

Figure 19: Arriba: log-retornos (rachas de alta y baja volatilidad). Abajo: predicción en precios obtenida revirtiendo la transformación logarítmica.

Lo que quedaría por explorar es modelar la volatilidad con un GARCH$(1, 1)$ [2, 3], que mejoraría los intervalos de predicción aunque no cambie la predicción puntual.

7.2 Serie B – Exploración con Gradient Boosting

Como exploración adicional, probé un modelo **HistGradientBoosting** (scikit-learn) para la serie B. Las features usadas fueron: día de la semana, mes, día del año, índice de año, términos de Fourier semanales y anuales, y tres lags anuales (lag_{364}, lag_{365}, lag_{366}, el mismo día del año anterior ± 1 día).

La ventaja de este enfoque es que el lag del año anterior aporta el nivel base de cada día directamente, y el árbol de gradiente puede capturar interacciones no lineales entre el día de la semana y el mes sin necesitar diferenciación. En validación sobre el año 2002, el RMSE fue de 514, frente al RMSE de 710 del SARIMA+Fourier.

No se usó para la predicción final porque el objetivo de esta práctica era explorar los modelos SARIMA/SARIMAX. De todas formas el resultado apunta a que para series con dependencias de nivel interanuales, los modelos basados en árboles con lags anuales pueden ser una alternativa interesante.

7.3 Serie D – Transformación Box-Cox

La transformación Box-Cox [1] elige automáticamente el exponente que mejor estabiliza la varianza. La serie D crece bastante así que pensé que podría haber heterocedasticidad, pero el test de Levene dio $p = 0.31$: la varianza ya era constante. El lambda óptimo resultó $\lambda = 0.35$, entre logaritmo y raíz cuadrada.

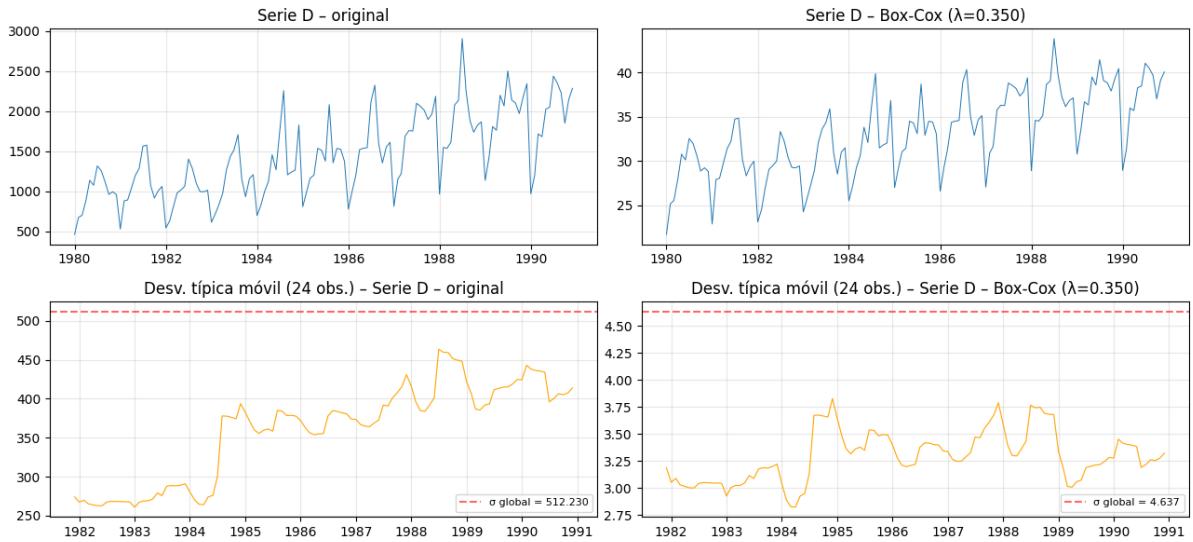

Figure 20: Desviación típica móvil antes y después de Box-Cox ($\lambda = 0.35$). La mejora es pequeña porque la serie ya era bastante homocedástica.

Ajusté un SARIMA sobre la serie transformada y el RMSE en validación fue de 264, peor que el modelo directo (186). La transformación no ayuda porque el problema no era heterocedasticidad sino tendencia, que ya maneja el SARIMA con sus componentes AR.

8 Resultados y Conclusiones

Table 6: Modelos finales y métricas de validación

Serie	Modelo	RMSE (val.)	Obs. train
A	SARIMA$(2,0,1)(1,1,1)_5$	6.16	2025
B	SARIMA$(2,0,1)(1,1,1)_7$ + Fourier $K = 5$	710.10	3287
C	SARIMA$(1,0,0)(0,1,1)_{12}$ + tendencia (40 años)	0.287	480
D	SARIMA$(0,0,0)(1,0,0)_{12}$	186.24	132

Las principales conclusiones de la práctica son:

- **Serie A**: La diferenciación estacional $D = 1$ con $m = 5$ captura el patrón de semana laboral. Los parámetros AR(2), MA(1) y los estacionales AR(1), MA(1) añaden flexibilidad para modelar la autocorrelación de corto y largo plazo.
- **Serie B**: La doble estacionalidad se puede manejar combinando SARIMA (para la componente semanal) con términos de Fourier como regresores externos (para la componente anual). El uso de Fourier es especialmente útil cuando la serie tiene dos frecuencias estacionales que no pueden capturarse con un solo periodo m.
- **Serie C**: Limitar los datos de entrenamiento a los últimos 40 años es una decisión importante: los datos de 1880–1984 tienen una pendiente de calentamiento muy diferente a la actual y añadir un regresor de tendencia lineal junto con la ventana temporal adecuada mejora sustancialmente las predicciones.
- **Serie D**: Con solo 132 observaciones, los modelos simples generalizan mejor. SARIMA$(0,0,0)(1,0,$ con un único parámetro estacional fue el más robusto en validación.

Trabajo futuro

Para la serie B, una línea interesante sería usar el **HistGradientBoosting** como modelo principal. Los resultados en validación sugieren que los lags anuales combinados con features de calendario pueden capturar mejor las interacciones no lineales entre el día de la semana, el mes y el nivel del año anterior. Con una validación rolling sobre varios años y una búsqueda de hiperparámetros más exhaustiva, podría mejorar sustancialmente el RMSE.

References

[1] Box, G. E. P. & Cox, D. R. (1964). *An analysis of transformations*. Journal of the Royal Statistical Society B, **26**(2), 211–252.

[2] Engle, R. F. (1982). *Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation*. Econometrica, **50**(4), 987–1007.

[3] Bollerslev, T. (1986). *Generalized autoregressive conditional heteroscedasticity*. Journal of Econometrics, **31**(3), 307–327.

[4] Hyndman, R. J. & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3rd ed. OTexts. https://otexts.com/fpp3/

[5] Levene, H. (1960). *Robust tests for equality of variances*. In Olkin, I. et al. (Eds.), *Contributions to Probability and Statistics*, pp. 278–292. Stanford University Press.